



Universidad del Valle de Guatemala
Facultad de Ingeniería
Departamento de Ciencias de la Computación
CC3084 Data Science, Semestre II 2026

Laboratorio 2

Deep Learning para Series de Tiempo

Fernando Rueda - 23748
Fernando Hernández - 23645
Guatemala, 1 agosto de 2026

Repositorio: <https://github.com/FerAHMz/lab2-ds>

Índice

1. Introducción	2
2. Modelos LSTM	2
2.1. Metodología común	2
2.2. Serie total de visitantes	2
2.3. Serie frontera La Aurora	3
2.4. Resultados y selección del mejor modelo	4
2.5. Comparación con el Laboratorio 1	5
3. Similitud de las series con catch22	6
3.1. La idea de catch22	6
3.2. Matriz de características y análisis	6
3.3. Interpretación	9
4. LSTM con características de catch22	10
5. Conclusiones	11

1. Introducción

Este laboratorio parte de las series mensuales de ingreso de viajeros internacionales a Guatemala que construimos en el Laboratorio 1, y usa exactamente los mismos conjuntos de entrenamiento y prueba, la partición temporal 70/30 con entrenamiento de enero 2009 a marzo 2021, 147 meses, y prueba de abril 2021 a junio 2026, 63 meses. El trabajo tiene dos partes. La primera modela dos de esas series con redes LSTM y compara el resultado contra los modelos clásicos del laboratorio anterior. La segunda explora la similitud de las siete series con el algoritmo catch22 y prueba si sus características ayudan a un modelo de pronóstico.

De las siete series elegimos dos para modelar con LSTM, el total de visitantes y la frontera La Aurora, que es la vía aérea. Elegimos La Aurora porque es una serie limpia sin meses en cero y porque su mejor modelo del Laboratorio 1 fue un SARIMA, lo que hace la comparación con la red significativa. La medida en todas las series es visitantes, la suma de turistas y excursionistas.

Todo el código está en el repositorio, repartido en cuatro cuadernos, y este informe reúne los resultados y su lectura en un solo documento.

2. Modelos LSTM

2.1. Metodología común

Las dos series se modelaron con el mismo procedimiento. La serie se escala con un MinMax ajustado solo con el entrenamiento, para no filtrar información de la prueba. Luego se convierte en un problema supervisado con ventanas deslizantes, cada ventana de lookback meses consecutivos predice el mes siguiente. Para cada serie se entrenan dos configuraciones distintas de red, y cada configuración se afina con una rejilla de hiperparámetros sobre el tamaño de ventana, las unidades de la capa LSTM y la tasa de aprendizaje. La selección de la mejor combinación se hace por el RMSE sobre un tramo de validación temporal, el 15 % final del entrenamiento, así la prueba nunca participa en el ajuste. Cada modelo se entrena con early stopping para cortar antes del sobreajuste.

El modelo elegido de cada configuración se evalúa sobre la prueba de dos formas. La predicción a un paso alimenta al modelo con los valores reales anteriores y mide su calidad como predictor del mes siguiente, que es la misma modalidad con la que se eligió el mejor modelo en el Laboratorio 1. El pronóstico multi-paso deja al modelo alimentarse de sus propias predicciones durante los 63 meses, donde el error se acumula. Como referencia se usa una línea base naïve estacional, que predice cada mes con el valor del mismo mes del año anterior. Un modelo que no supere esa línea no aporta nada. Las métricas son RMSE, MAE y MAPE en visitantes reales.

2.2. Serie total de visitantes

Para el total las dos configuraciones son una LSTM simple de una capa, la Config A, y una LSTM apilada de dos capas, la Config B. La rejilla eligió para la Config A un lookback de 12, 64 unidades y tasa 0.01, y para la Config B un lookback de 24, 64 unidades y tasa 0.01. La figura 1 muestra la predicción de las dos configuraciones sobre la prueba, y la figura 2 las curvas de pérdida, donde se ve que el early stopping cortó antes de que la validación empezara a subir.




Figura 1: Total de visitantes, predicción a un paso y pronóstico multi-paso de las dos configuraciones.




Figura 2: Curvas de pérdida de entrenamiento y validación de las dos configuraciones del total.

2.3. Serie frontera La Aurora

Para La Aurora las configuraciones son una LSTM con Dropout, la Config A, y una LSTM bidireccional, la Config B. La rejilla eligió para la Config A un lookback de 12, 64 unidades y tasa 0.01. La figura 3 muestra la serie con el corte de la partición y la figura 4 la predicción de las dos configuraciones sobre la prueba.




Figura 3: Serie de La Aurora con el corte de la partición 70/30 del Laboratorio 1.




Figura 4: La Aurora, predicción a un paso y pronóstico multi-paso de las dos configuraciones.

2.4. Resultados y selección del mejor modelo

El cuadro 1 resume el mejor modelo de cada configuración con sus métricas de predicción a un paso sobre la prueba, junto con la línea base naive. Se mantiene el criterio del Laboratorio 1, se elige por menor MAE a un paso, que refleja el uso operativo de pronosticar el mes siguiente.

Serie	Modelo	lookback	units	RMSE	MAE	MAPE
Total	LSTM A, simple	12	64	81702	68227	26.5
Total	LSTM B, apilada	24	64	72306	57615	22.7
Total	Naive estacional	–	–	93379	65996	32.2
La Aurora	LSTM A, con Dropout	12	64	27483	22923	22.8
La Aurora	LSTM B, bidireccional	12	32	42921	38026	38.6
La Aurora	Naive estacional	–	–	37367	29404	34.7

Cuadro 1: Mejor modelo de cada configuración LSTM por serie, predicción a un paso.

Para el total el mejor modelo es la LSTM apilada, la Config B, con MAE 57,615, la única que supera la línea base naive en las dos métricas. Para La Aurora el mejor modelo es la LSTM con Dropout, la Config A, con MAE 22,923, muy por debajo del naive. En La Aurora la Config B queda incluso peor que el naive, así que la ventaja es específica de la Config A. En las dos series el pronóstico multi-paso se degrada mucho frente al de un paso, algo esperable porque el entrenamiento termina en el piso pandémico y el modelo, al alimentarse de sus propias predicciones a cinco años, no tiene información de la reapertura.

2.5. Comparación con el Laboratorio 1

El punto 1.4 pide comparar el mejor LSTM contra el mejor modelo del Laboratorio 1 para cada serie. Como la partición es idéntica en los dos laboratorios, la misma prueba, la misma modalidad a un paso y las mismas métricas en visitantes reales, las cifras son directamente comparables. En el Laboratorio 1 el modelo elegido para las dos series fue un SARIMA(0,1,1)(1,1,0) con período 12 sobre el logaritmo. El cuadro 2 pone lado a lado los dos enfoques.

Serie	Modelo	RMSE	MAE
Total	SARIMA en log, Lab 1	80789	50430
Total	LSTM Config B, Lab 2	72306	57615
La Aurora	SARIMA en log, Lab 1	45742	24747
La Aurora	LSTM Config A, Lab 2	27483	22923

Cuadro 2: Mejor LSTM contra el mejor modelo del Laboratorio 1, predicción a un paso.

El resultado depende de la serie. Para el total el SARIMA conserva el primer lugar por MAE, 50,430 contra 57,615 de la red, aunque la LSTM apilada le gana por RMSE, 72,306 contra 80,789, porque comete menos errores extremos en los meses difíciles de la recuperación. Manteniendo el criterio de menor MAE, el modelo clásico sigue siendo el mejor para el total, y además es más barato de estimar e interpretable en sus componentes.

Para La Aurora el resultado es unánime y favorece a la red. La LSTM con Dropout gana en las dos métricas, MAE 22,923 contra 24,747 y RMSE 27,483 contra 45,742, con una diferencia grande en RMSE que viene de los primeros meses de la reapertura, donde el SARIMA arrastraba todavía el régimen del cierre. La diferencia entre las dos series tiene sentido. La Aurora es la vía aérea, con un calendario estacional limpio y regular que la red aprende bien, mientras que el total mezcla varios mercados y el modelo clásico ya lo capturaba con eficiencia. La conclusión es que la LSTM no desbanca al SARIMA en todas las series, solo en la que tiene una estructura que la red puede

explotar.

3. Similitud de las series con catch22

3.1. La idea de catch22

catch22 es un conjunto de 22 características canónicas de series de tiempo. Nace del proyecto hctsa, que reunió más de siete mil características posibles, y tras evaluarlas sobre cientos de problemas de clasificación encontró que la mayoría son redundantes. catch22 es el subconjunto que conserva casi todo el poder discriminativo siendo mucho más barato de calcular. Cada característica resume un aspecto de la dinámica de la serie, la distribución de sus valores, la autocorrelación lineal y no lineal, la periodicidad, el escalamiento de las fluctuaciones y el conteo de eventos extremos, entre otros. El resultado es que cualquier serie, sin importar su largo o su escala, queda representada por un vector de 22 números comparables. Eso convierte la pregunta difícil de qué tan parecidas son dos series en un problema de distancia entre vectores, sobre el que se aplican herramientas estándar como PCA, clustering y mapas de distancia.

3.2. Matriz de características y análisis

Se extrajeron las 22 características de las siete series completas, las de 210 meses, y se armó una matriz de siete filas por veintidós columnas que se estandarizó antes de analizarla. Sobre esa matriz se aplicaron las técnicas de exploración del enunciado. La figura 5 muestra las series en el plano de los dos primeros componentes principales, la figura 6 el dendrograma del clustering jerárquico, la figura 7 el mapa de calor de la matriz estandarizada, la figura 8 las correlaciones entre características y la figura 9 el mapa de distancias entre series.




Figura 5: Las siete series en el plano de los dos primeros componentes principales.




Figura 6: Dendrograma con enlace de Ward sobre las 22 características estandarizadas.




Figura 7: Matriz estandarizada de series por características de catch22.




Figura 8: Correlaciones entre las 22 características a través de las siete series.




Figura 9: Distancias entre series en el espacio catch22 estandarizado.

3.3. Interpretación

Las tres representaciones cuentan la misma historia. El par de series más parecidas es el total y América del Centro, con la distancia más corta de todas, 2.67, y en el plano de componentes quedan prácticamente superpuestas. Tiene lógica, América del Centro es la región que domina el total, así que sus dinámicas son casi la misma serie. Le siguen América del Centro con Valle Nuevo y el total con Valle Nuevo, una frontera terrestre de tráfico mayoritariamente centroamericano.

Los dos primeros componentes explican el 63 % de la varianza. El primero separa las series suaves y persistentes de las más erráticas, cargado por características de rugosidad, potencia espectral de baja frecuencia y rachas largas sobre la media. El segundo separa las series según qué tan marcado y a qué plazo es su ciclo anual, cargado por características de periodicidad y de memoria de la autocorrelación. Esos dos ejes son las características más importantes para diferenciar las series.

Hay tres grupos naturales, que el dendrograma y k-means coinciden en señalar. El primero es el bloque centroamericano y terrestre, con el total, América del Centro, Valle Nuevo y San Cristóbal, de crecimiento alto y pico en diciembre. El segundo son los mercados lejanos, América del Norte y Europa, de estacionalidad anual muy fuerte con picos propios en julio y marzo, crecimiento prepandemia bajo y paro total en 2020. El tercero es La Aurora sola, la vía aérea no se parece lo suficiente a nada más.

Un hallazgo importante es que las categorías del enunciado no coinciden con los grupos dinámicos. Las tres fronteras quedan repartidas y las tres regiones también. Lo que agrupa a las series no es la categoría administrativa sino el tipo de viajero que las alimenta, flujo regional terrestre por un lado y mercados lejanos estacionales por otro, con el aeropuerto como caso aparte.

La serie más atípica es La Aurora. Es la única que forma un grupo propio, su vecino más cercano está a 7.63, mucho más lejos que el 2.67 del par total y Centro, y en el PCA queda sola en su cuadrante. La razón está en su naturaleza, es la única serie puramente aérea, con un perfil estacional propio, un cierre pandémico más largo que las fronteras terrestres y una recuperación que la llevó muy por encima de su nivel de 2019.

Los agrupamientos son consistentes con el análisis exploratorio del Laboratorio 1. catch22 junta a las dos series que el EDA había marcado como las más estacionales, Norte y Europa, y las separa del bloque centroamericano de mayor tendencia de crecimiento. La volatilidad y el efecto de la pandemia que medimos en el EDA van en el mismo sentido que la separación por rugosidad del primer componente, y las diferencias de autocorrelación que veíamos en las funciones ACF son las que ordenan el segundo componente.

Tres descubrimientos que el análisis exploratorio no hacía evidentes cierran esta parte. El primero, el total es dinámicamente casi redundante con América del Centro, a distancia 2.67, la mitad de la siguiente, así que modelar el total equivale en la práctica a modelar Centro más ruido. El segundo, pertenecer a una misma categoría no implica parecerse, Valle Nuevo está más cerca de una región, América del Centro a 3.44, que de su compañera de categoría La Aurora, a 7.63. El tercero, buena parte de las 22 características se mueven juntas en este conjunto, los tres primeros componentes acumulan el 84 % de la varianza, porque el bloque de ceros de la pandemia arrastra varias características a la vez.

4. LSTM con características de catch22

El punto 2.14 pide un nuevo modelo LSTM que use las características de catch22 como variables adicionales, comparado con el mejor LSTM de una de las series. Lo hicimos para La Aurora. Las 22 características se extraen sobre cada ventana deslizante de la serie, y el modelo comparte la misma rama secuencial del mejor LSTM base, la Config A, y le concatena el vector de 22 características antes de la capa de salida. Los dos modelos usan los mismos hiperparámetros y el mismo entrenamiento, así que cualquier diferencia viene de las características, no del ajuste. El cuadro 3 resume el resultado y la figura 10 la predicción.

Modelo	RMSE	MAE	MAPE
LSTM base	27483	22923	22.8
LSTM más catch22	62648	46499	54.9
Naive estacional	37367	29404	34.7

Cuadro 3: LSTM base contra LSTM con características de catch22, La Aurora, predicción a un paso.




Figura 10: La Aurora, predicción a un paso del LSTM base y del LSTM con catch22.

El resultado va en contra de la intuición inicial. Agregar las características de catch22 no mejoró el pronóstico, lo empeoró, el RMSE sube de 27,483 a 62,648 y el modelo queda incluso por debajo de la línea base naive. El modelo base reproduce exactamente el resultado de la Config A, así que la degradación es de las características, no de un error de montaje. Hay dos razones. Primero, los datos son pocos, el entrenamiento tiene 135 ventanas y agregar 22 variables da margen para sobreajustar. Segundo, y más importante, hay un cambio de régimen, las ventanas del tramo de prueba, la reapertura pospandemia, tienen una dinámica muy distinta de las del entrenamiento, así que sus características caen fuera de la distribución con la que se entrenó y empujan las predicciones lejos. La rama secuencial pura es más robusta a eso porque solo necesita los últimos doce valores reales. La conclusión es que catch22 es muy útil para caracterizar y comparar series, pero como entrada adicional a un modelo de pronóstico sobre una serie corta y con cambio de régimen, agrega ruido más que señal.

5. Conclusiones

Las redes LSTM no ganan siempre al modelo clásico. Para el total el SARIMA del Laboratorio 1 conserva el primer lugar por MAE, mientras que para La Aurora la LSTM con Dropout lo supera en las dos métricas. La diferencia depende de la estructura de cada serie, la red aprovecha el calendario limpio y regular de la vía aérea, y no aporta lo mismo donde el modelo clásico ya capturaba bien la dinámica. En las dos series el mejor modelo supera con claridad la línea base naive, así que ambos enfoques aportan estructura real.

El análisis con catch22 mostró que la similitud entre las series responde al tipo de viajero que las alimenta y no a la categoría administrativa del enunciado, con tres grupos claros, el bloque centroamericano terrestre, los mercados lejanos estacionales y La Aurora como caso propio. El total resultó dinámicamente casi redundante con América del Centro, y La Aurora la serie más atípica del conjunto, lo que justifica haberla modelado por separado.

Finalmente, usar las características de catch22 como variables adicionales de un LSTM no mejoró el pronóstico de La Aurora, lo degradó, por la poca cantidad de datos y el cambio de régimen de la prueba. catch22 rinde para describir y comparar series, que es su propósito, pero no como insumo directo de un modelo de pronóstico en este caso.